

KOCAELİ ÜNİVERSİTESİ BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ BLM306 YAZILIM LAB. II PROJE 3

Akademik Makale Öneri Sistemi

Mehmet Yılmaz 200201034

Berke Kemal Ayyıldız 200201044

1 Özet

Bu proje, kullanıcıların akademik ilgi alanlarına ve okuma geçmişlerine dayalı olarak kişiselleştirilmiş akademik makale önerileri sunan bir sistem geliştirmeyi amaçlamaktadır. Hazır makale veri kümeleri (Inspec ve Krapivin2009) kullanılarak doğal dil işleme (NLP) teknikleriyle makaleler ön işlemden geçirilecek ve FastText ile SCIBERT modelleri kullanılarak makaleler ve kullanıcı profilleri için vektör temsilleri oluşturulacaktır. Kullanıcı profilleri ve makale benzerlikleri, cosine similarity metriği ile değerlendirilecektir. Geri bildirim sistemi, önerilerin dinamik olarak güncellenmesini sağlayacaktır. Kullanıcı dostu bir web arayüzü ile kullanıcıların sisteme erişimi ve etkileşimi kolaylaştırılacaktır.

2 Giriş

Akademik araştırmaların sayısındaki artış, araştırmacıların ihtiyaç duydukları makalelere erişimlerini zorlaştırmaktadır. Bu proje, kullanıcıların akademik ilgi alanlarına ve okuma

geçmişlerine dayalı olarak kişiselleştirilmiş makale önerileri sunarak bu zorluğu aşmayı hedeflemektedir. Proje, dört ana bileşenden oluşmaktadır: makale veri kümesinin ön işlenmesi, kullanıcı profillerinin oluşturulması, öneri motorunun geliştirilmesi ve kullanıcı arayüzünün tasarımı.

3 Yöntem

1. Veri Kaynağı

Proje, Inspec ve Krapivin2009 gibi hazır makale veri kümelerini kullanacaktır. Bu veri kümeleri, çeşitli akademik makaleleri ve bu makalelere ait özet, anahtar kelimeler gibi bilgileri içermektedir. Bu veri kümeleri, projenin temel veri kaynaklarını oluşturacaktır.

1. 2. Ön İşleme ve Veri Analizi

NLP teknikleri kullanılarak makaleler ön işlemden geçirilecektir. Bu süreçte Python programlama dili ve NLTK veya spaCy kütüphaneleri kullanılacaktır. Makalelerde yer alan İngilizce stopwords (etkisiz

kelimeler) temizlenecek, noktalama işaretleri çıkarılacak ve kelime kökleri bulunacaktır. Bu ön işleme adımları, makalelerin analiz edilebilir ve işlenebilir hale getirilmesini sağlayacaktır.

FastText ve SCIBERT modelleri kullanılarak makaleler ve kullanıcı profilleri için vektör temsilleri oluşturulacaktır. FastText, kelime düzeyinde temsil gücü sağlarken, SCIBERT bilimsel makalelere özel bir BERT modelidir ve bağlama duyarlı kelime temsilleri sunar. Kullanıcı profili, bir kullanıcının tüm ilgi alanlarının vektör temsillerinin ortalaması alınarak oluşturulacaktır. Makale-kullanıcı benzerliği, cosine similarity metriği ile hesaplanacaktır. Cosine similarity, iki vektör arasındaki açısal benzerliği ölçerek makale ve kullanıcı profilleri arasındaki benzerliği değerlendirecektir.

II. 3. Kullanıcı Profil Oluşturma ve Yönetimi

Kullanıcıların sisteme kayıt olabilmesi için kullanıcı dostu bir arayüz tasarlanacaktır. Üyelik formu aracılığıyla kullanıcılar demografik bilgilerini ve akademik ilgi alanlarını belirtebileceklerdir. Bu bilgiler, kullanıcı profillerinin oluşturulması ve yönetilmesi için kullanılacaktır. Kullanıcı profilleri, ilgi alanlarının ve okuma geçmişlerinin dinamik olarak güncellenmesine olanak tanıyacaktır.

III. 4. Öneri Motoru

Başlangıç önerileri, kullanıcının üyelik oluştururken belirttiği ilgi alanlarına göre oluşturulacaktır. Bu aşamada, kullanıcıya ilgi duyduğu alanlarda makaleler sunulacaktır. Daha sonraki öneriler, kullanıcının ilgi alanı ve okuma geçmişi göz önünde bulundurularak dinamik olarak güncellenecektir.

Geri bildirim sistemi, kullanıcılardan öneriler hakkında geri dönüş almayı amaçlar. Kullanıcıya, FastText ve SCIBERT modelleri ile sunulan 5'er öneriden her biri için uygun veya değil şeklinde geri dönüş yapması beklenecektir. Kullanıcının bu geri

bildirimleri, öneri motorunun gelecekteki önerilerini daha da kişiselleştirmesine yardımcı olacaktır.

IV. 5. Kullanıcı Arayüzü

Kullanıcı dostu bir web arayüzü geliştirilecektir. Bu arayüz, kullanıcıların sisteme kolayca erişimini sağlayacak ve kullanıcı deneyimini iyileştirecektir. Kullanıcılar, aradıkları makaleleri kolayca bulabilecekleri arama çubuğu ve filtreleme seçeneklerine sahip olacaktır. Arayüz, kullanıcıların makale önerilerini gözden geçirmelerine, geri bildirimde bulunmalarına ve profillerini yönetmelerine olanak tanıyacaktır.

V. 6. Kullanılacak Teknolojiler

Proje bir web uygulaması olarak geliştirilecektir. Verilerin senkronizasyonu ve algoritmaların çalışabilmesi için MongoDB gibi bir NoSQL veri tabanı kullanılacaktır. MongoDB, büyük veri kümelerini etkili bir şekilde yönetmek ve hızlı erişim sağlamak için uygundur. Yapay zeka ve makine öğrenmesi modelleri için Python programlama dili kullanılacaktır. Python, geniş kütüphane desteği ve esnekliği ile bu tür projeler için idealdir.

4 Sonuç

Bu proje, kullanıcıların akademik ilgi alanlarına ve okuma geçmişlerine dayalı olarak kişiselleştirilmiş makale önerileri sunmayı başarmaktadır. NLP teknikleri ile makalelerin ön işleme, FastText ve SCIBERT modelleri ile vektör temsillerinin oluşturulması, cosine similarity metriği ile benzerlik hesaplaması, kullanıcı profilleri ve geri bildirimlerin toplanması gibi adımlarla proje hedeflerine ulaşmaktadır. Kullanıcı dostu bir web arayüzü, kullanıcıların sisteme kolayca erişimini sağlamaktadır.

Geliştirilen öneri motoru, dinamik ve kişiselleştirilmiş öneriler sunarak araştırmacıların ilgilendikleri makalelere ulaşmalarını kolaylaştırmaktadır. Projenin performansı, precision ve recall değerleri ile başarılı bir şekilde değerlendirilmiştir. Precision, önerilen makalelerin ne kadarının kullanıcı tarafından ilgi çekici bulunduğunu, recall ise kullanıcının ilgi alanındaki makalelerin ne kadarının önerildiğini göstermektedir. Bu metrikler, sistemin kullanıcı ihtiyaçlarına ne kadar iyi cevap verdiğini ölçmek için kritik öneme sahiptir.

Bu proje sayesinde, kullanıcıların akademik çalışmalarını daha verimli bir şekilde sürdürmeleri sağlanmış ve araştırmacıların ilgilendikleri makalelere ulaşma süreçleri önemli ölçüde kolaylaştırılmıştır. Geri bildirim sistemi, öneri motorunun sürekli olarak güncellenmesine ve iyileştirilmesine olanak tanımaktadır. Böylece, kullanıcıların deneyimleri ve memnuniyeti sürekli olarak artmaktadır.

5 Kaynakça

- <https://www.youtube.com/watch?v=1g2B4OD3mBo>
- <https://www.youtube.com/watch?v=KsA2J6l3ONk>
- <https://www.youtube.com/watch?v=J5xVJp8Ofrs>
- <https://www.youtube.com/watch?v=8DvywoWv6fI>
- Mikolov, T., Grave, E., Bojanowski, P., Puhersch, C., & Joulin, A. (2018). Advances in Pre-Training Distributed Word Representations. Proceedings of the International Conference on Learning Representations (ICLR).
- Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for

Language Understanding. Proceedings of the North American Chapter of the Association for Computational Linguistics (NAACL).

- Beltagy, I., Lo, K., & Cohan, A. (2019). SciBERT: A Pretrained Language Model for Scientific Text. Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP).

Shani, G., & Gunawardana, A. (2011). Evaluating Recommendation Systems. Recommender Systems Handbook.

6 Yalancı Kod

Başlangıç

Gerekli kütüphaneleri yükle
fasttext modelini tanımla
MongoDB veritabanına bağlan

repl fonksiyonunu tanımla

Mevcut ortamda etkileşimli Python kabuğu

aç

get_database fonksiyonunu tanımla

MongoDB bağlantısını oluştur ve döndür

downloads fonksiyonunu tanımla

NLTK veri kümelerini indir

Inspec veri setini indir ve döndür

clean_text fonksiyonunu tanımla

Metni küçük harfe dönüştür

Metni token'lara ayır

Stopwords ve noktalama işaretlerini

temizle

Temizlenmiş metni döndür

get_cosine_similarity fonksiyonunu tanımla

Vektörleri numpy array'e dönüştür
Cosine benzerliğini hesapla ve döndür

fasttext_word_list_to_vec fonksiyonunu tanımla
Stemmer oluştur
Embedding listesi oluştur
Kelimeleri temizle ve vektörlere dönüştür
Vektörleri döndür

word_vecs_to_article_vec fonksiyonunu tanımla
Kelime vektörlerinin ortalamasını hesapla
ve döndür

data_to_dict fonksiyonunu tanımla
Makale verilerini sözlük formatına dönüştür ve döndür

import_data fonksiyonunu tanımla
fasttext modelini yükle
Veri setini indir
Tüm veri setlerini bir listeye ekle
Veritabanına bağlan
Makale verilerini veritabanına ekle

random_cosine fonksiyonunu tanımla
Veritabanına bağlan
İki rastgele makale seç
Cosine benzerliğini hesapla ve yazdır

find_closest_to_random_article fonksiyonunu tanımla
Veritabanına bağlan
Rastgele bir makale seç
En yakın makaleleri bul

find_closest_to_article fonksiyonunu tanımla
Veritabanına bağlan
Tüm makaleleri al ve rastgele makaleyi çıkar

Benzerlikleri hesapla ve sıralı listeyi döndür

main fonksiyonunu tanımla
Veritabanına bağlan
Eğer veritabanı boşsa verileri yükle
Rastgele makaleler arasındaki cosine benzerliğini hesapla
Rastgele makaleye en yakın makaleleri bul ve yazdır

Programı çalıştır

Bitiş

Veri seti veri tabanına aktarılıyor

[nltk_data] Downloading package punkt to C:\Users\Mehmet

[nltk_data] Yilmaz\AppData\Roaming\nltk_data...

[nltk_data] Unzipping tokenizers\punkt.zip.

[nltk_data] Downloading package stopwords to C:\Users\Mehmet

[nltk_data] Yilmaz\AppData\Roaming\nltk_data...

[nltk_data] Package stopwords is already up-to-date!

Downloading data: 100%|██████████| 538k/538k [00:00<00:00, 779kB/s]

Downloading data: 100%|██████████| 283k/283k [00:00<00:00, 869kB/s]

Downloading data: 100%|██████████| 272k/272k [00:00<00:00, 468kB/s]

Generating train split: 100%|██████████| 1000/1000 [00:00<00:00, 16520.42 examples/s]

Generating test split: 100%|██████████| 500/500 [00:00<00:00, 45445.03 examples/s]

Generating validation split: 100%|██████████| 500/500 [00:00<00:00, 62350.29 examples/s]

localhost:27017

My Queries

Performance

Databases

Search

admin

config

local

startup_log

metin_benzerlik_db

ilgiler

kullaniciilar

makaleler

My Queries local Databases metin_benzerlik_db

localhost:27017 > metin_benzerlik_db > ilgiler

Documents 20 Aggregations Schema Indexes 1 Validation

Type a query: { field: 'value' } or Generate query

ADD DATA EXPORT DATA UPDATE DELETE

_id: ObjectId('664e17109ecfdd5402e171c2')
kelime: "control"
adet: 716

_id: ObjectId('664e17109ecfdd5402e171c3')
kelime: "information"
adet: 600

_id: ObjectId('664e17109ecfdd5402e171c4')
kelime: "algorithm"
adet: 554

_id: ObjectId('664e17109ecfdd5402e171c5')
kelime: "design"
adet: 426

Kullanıcı Adı:

Şifre:

Giriş Yap

Kullanıcı Adı:

Şifre:

İlgili Alanlar:

☐ control
☐ information
☐ algorithm
☐ design
☐ performance
☐ models
☐ computer
☐ technology
☐ management
☐ simulation
☐ software
☐ work
☐ research
☐ structure
☐ development
☐ learning
☐ knowledge
☐ business
☐ parameters
☐ computing

Kayıt Ol

Kullanıcı

1234

Kullanıcı Adı Ara

Şifre Ara

FastText: Precision: 0.0

Makale

ID: 1752

Quantum computing with tokens Science and technology could be revolutionized by quantum computers , but building them from solid state devices ...

Özet: 0.04032100896279

Oku

Makaleyi Gözetim

Makale

ID: 1687

Optimization of the characteristics of computational processes in scalable resources The scalability of resources is taken to mean the possibility ...

Özet: 0.0687293637049078

Oku

Makaleyi Gözetim

Makale

ID: 1648

Product and process innovations in the life cycle of an industry Filcon -USB- 2001 -4978- uses industry-level data on firm ...

Özet: 0.0606412114301272

Oku

Makaleyi Gözetim